Estudo de acurácia de Modelos de Machine Learning para classificiação

João Victor Pietchaki Gonçalves
Leonardo Eizo Sakai
Nicole Rodrigues do Nascimento
Vitor Gabriel Pignatari

Table of contents

1 Introdução **2**

2 Experimento **2**
2.1 Hipóteses 2
2.2 Fatores e Níveis 2
2.3 Unidade Experimental 2
2.4 Variável Resposta 3
2.5 Materiais e Instrumentos 3
2.6 Casualização 3
2.7 Metodologia de Execução 4
2.8 Dados Coletados 4

3 Checagem de adequação do modelo **6**
3.1 Suposição de normalidade 6
3.2 Verificação de independência 7
3.3 Teste de homogeneidade de variâncias (Teste de Bartlett) 8

4 ANOVA **9**
4.1 Estimação dos parâmetros 9
4.2 Teste de Tukey 10

5 Conclusão **10**

6 Recomendações para estudos futuros **11**

7 Referências **11**

1 Introdução

Para o primeiro projeto integrador da matéria de Planejamento de Experimentos o experimento escolhido foi um estudo da acurácia de diferentes modelos de Machine Learning. O tema foi proposto considerando conceitos vistos em algumas matérias optativas, e o interesse em ver na prática quais modelos seriam mais eficientes.

2 Experimento

2.1 Hipóteses

- H0: Todos os modelos tem o mesmo desempenho.
- H1: Pelo menos um modelo apresenta desempenho diferente dos outros.

2.2 Fatores e Níveis

Neste experimento serão testados quatro modelos de Machine Learning: Random Machines, Árvores de decisão, KNN e Regressão Logística. Por ser um estudo com apenas um fator, os níveis dos fatores correspondem aos próprios tratamentos.

2.3 Unidade Experimental

As Unidades Experimentais utilizadas foram 7 simulações de duas distribuições normais bivariadas com 2500 elementos cada, sendo $C_1 = \begin{pmatrix} X_1 \\ Y_1 \end{pmatrix} \sim N\left[\begin{pmatrix} 60 \\ 50 \end{pmatrix}, \begin{pmatrix} 25 & 0 \\ 0 & 25 \end{pmatrix}\right]$ e $C_2 = \begin{pmatrix} X_2 \\ Y_2 \end{pmatrix} \sim N\left[\begin{pmatrix} 45 \\ 60 \end{pmatrix}, \begin{pmatrix} 36 & 0 \\ 0 & 36 \end{pmatrix}\right]$ resultando em amostras de 5000 elementos. Para cada simulação foram usadas as seguintes seeds: 28062005, 16071998, 11052006, 14072001, 123, 321, 123456.

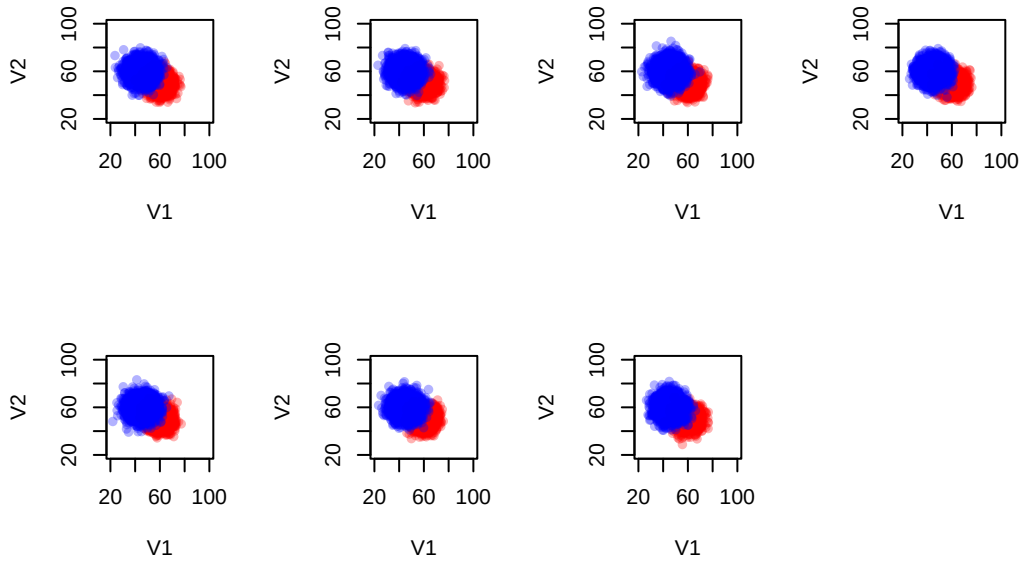

Neste gráfico C_1 está representado em vermelho e C_2 em azul.

2.4 Variável Resposta

A variável resposta será a acurácia dos modelos, ou seja, a proporção de classificações corretas em relação ao total de classificações feitas, calculada como $\text{Acc} = \frac{n\ de\ acertos}{total\ de\ observaes}$.

2.5 Materiais e Instrumentos

Este experimento foi realizado primariamente utilizando a linguagem de programação R, com as bibliotecas: mvtnorm, tidyverse, caret, rpart, caTools e class. Além disso, foi utilizado o Github, para a colaboração entre os membros do grupo e versionamento do projeto.

2.6 Casualização

Dada a natureza computacional do experimento e a fim de reduzir a variação latente foi possível atribuir à cada unidade experimental todos os tratamentos.

2.7 Metodologia de Execução

Inicialmente foram gerados os dados a partir das distribuições normais bivariadas utilizando as seeds como explicado no item 2.3. Em sequência, foram treinados cada um dos modelos do experimento para cada amostra gerada, e calculadas as respectivas acurácias. Verificamos então as suposições do modelo linear para o DIC. Por fim, foi feita a análise de variância e teste de Tukey para verificar se as diferenças entre os modelos são significativas e agrupar tratamentos com efeitos semelhantes.

2.8 Dados Coletados

Devido ao grande número de dados coletados, exibimos os dados a partir de sua análise exploratória.

- Acurácias dos modelos para cada réplica

Modelo	Réplica 28062005	16071998	11052006	14072001	123	321	123456
RL	0.9480000	0.9473333	0.9573333	0.9533333	0.9453333	0.9473333	0.9493333
AD	0.9340000	0.9206667	0.9306667	0.9420000	0.9420000	0.9353333	0.9326667
KNN	0.9486667	0.9406667	0.9553333	0.9520000	0.9393333	0.9473333	0.9480000
RM	0.9486667	0.9460000	0.9580000	0.9520000	0.9440000	0.9500000	0.9493333

- Histograma das acurácias de cada modelo

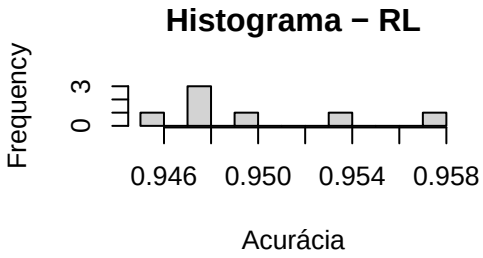

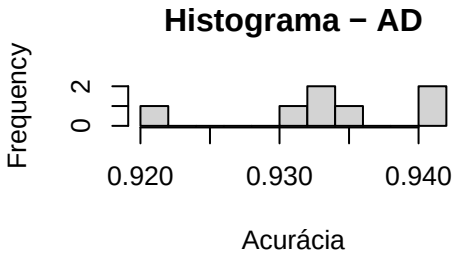

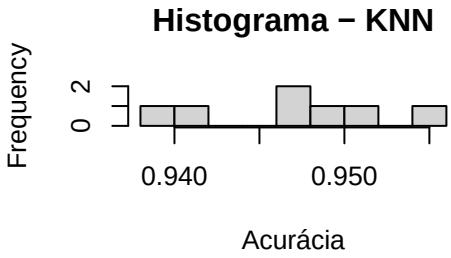

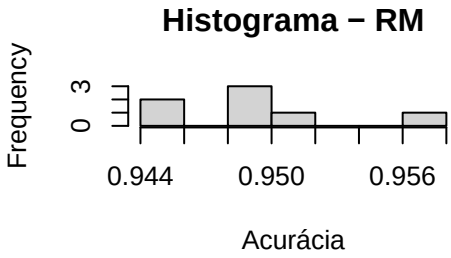

- Boxplot das acurácias

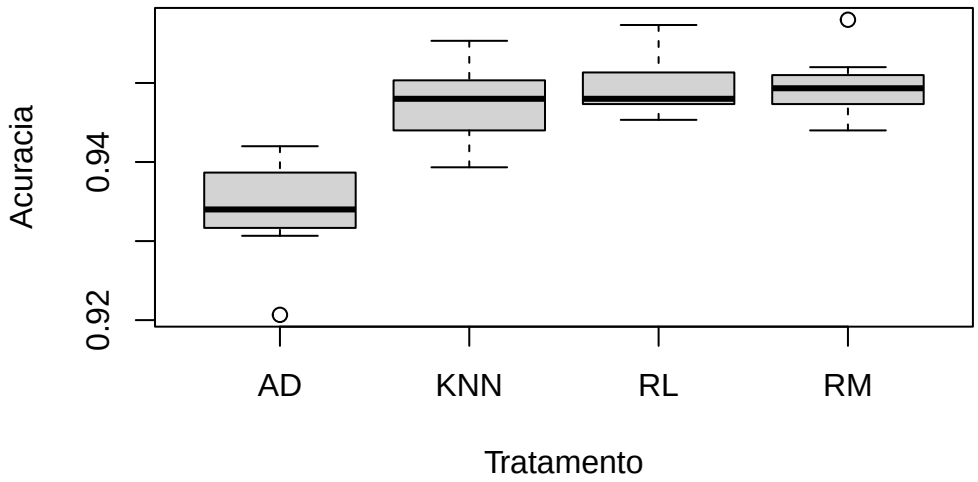

O boxplot revela um indício de que o modelo de Árvores de Decisões possui uma acurácia abaixo dos demais modelos, enquanto estes aparentam precisões bem similares, mas com diferenças

entre suas variações.

3 Checagem de adequação do modelo

3.1 Suposição de normalidade

```
$RL

    Jarque Bera Test

data:  x
X-squared = 1.0526, df = 2, p-value = 0.5908


$AD

    Jarque Bera Test

data:  x
X-squared = 0.44282, df = 2, p-value = 0.8014


$KNN

    Jarque Bera Test

data:  x
X-squared = 0.37307, df = 2, p-value = 0.8298


$RM

    Jarque Bera Test

data:  x
X-squared = 0.53759, df = 2, p-value = 0.7643
```

```r
modelo_aov <- aov(Acuracia ~ Tratamento, data = DIC)
jarque.bera.test(residuals(modelo_aov))
```

```
    Jarque Bera Test

data:  residuals(modelo_aov)
X-squared = 0.1902, df = 2, p-value = 0.9093
```

```r
qqnorm(modelo_aov$residuals, main = "QQ-Plot dos Resíduos", xlab = "Quantis Teóricos", ylab =
qqline(modelo_aov$residuals, col = "red", lwd = 2)
```

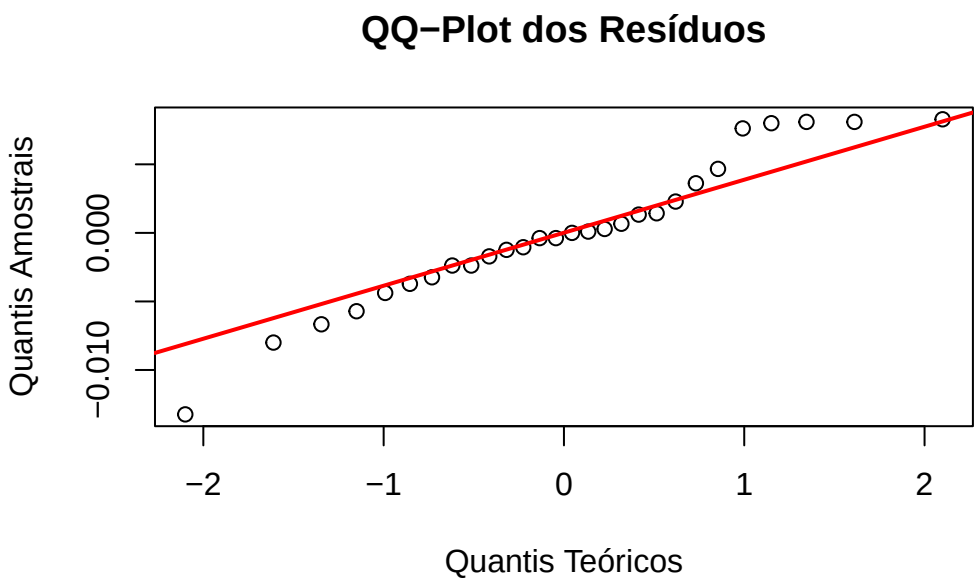

Fazendo uma avaliação visual do qq-plot dos resíduos, e o teste de Jarque Bera verificamos que a suposição de normalidade dos resíduos é atendida para os dados de cada tratamento, uma vez que o p-valor de cada teste é maior que 0.05, indicando que não há evidências suficientes para rejeitar a hipótese nula de normalidade dos dados.

3.2 Verificação de independência

Dado que os valores observados de cada tratamento seguem uma distribuição normal vamos avaliar a independência dos resíduos.

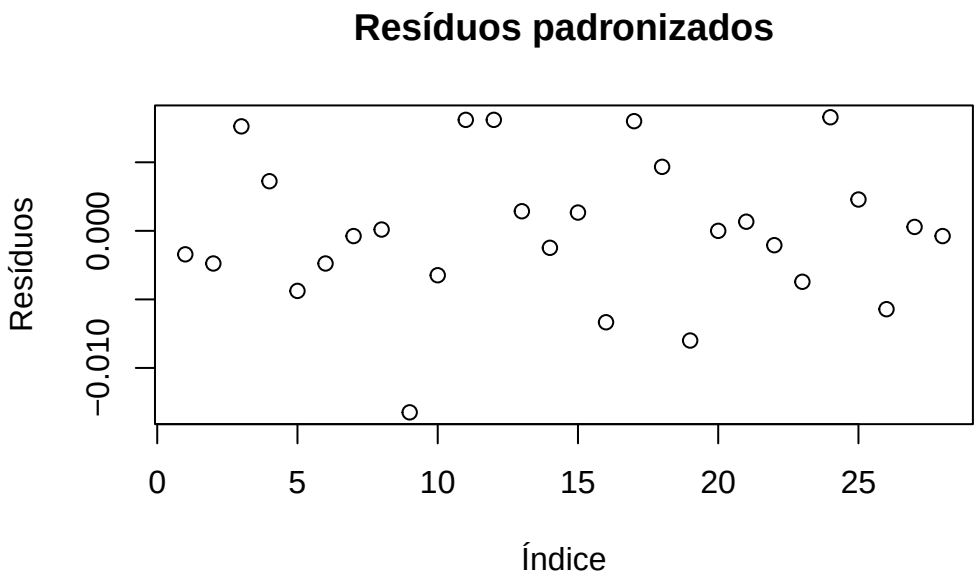

Como não observamos nenhum padrão no gráfico dos resíduos padronizados, podemos concluir que os resíduos são independentes.

3.3 Teste de homogeneidade de variâncias (Teste de Bartlett)

H_0: As variâncias dos resíduos são homogêneas entre os tratamentos.

H_1: Pelo menos um tratamento tem variância dos resíduos diferente dos outros.

```
    Bartlett test of homogeneity of variances

data:  Acuracia by Tratamento
Bartlett's K-squared = 2.2226, df = 3, p-value = 0.5275
```

Como o p-valor resultante do teste é maior do que 0.05, não rejeitamos a hipótese nula, ou seja, temos evidências de que as variâncias dos resíduos, de fato são homogêneas.

4 ANOVA

```
            Df    Sum Sq   Mean Sq F value   Pr(>F)
Tratamento   3 0.0012102 0.0004034   13.03 2.99e-05 ***
Residuals   24 0.0007432 0.0000310
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Como o resultado do p-valor do teste de ANOVA é menor que 0.05, rejeitamos a hipótese nula, e concluímos que há evidências de que pelo menos um dos modelos tem efeito sobre a acurácia.

4.1 Estimação dos parâmetros

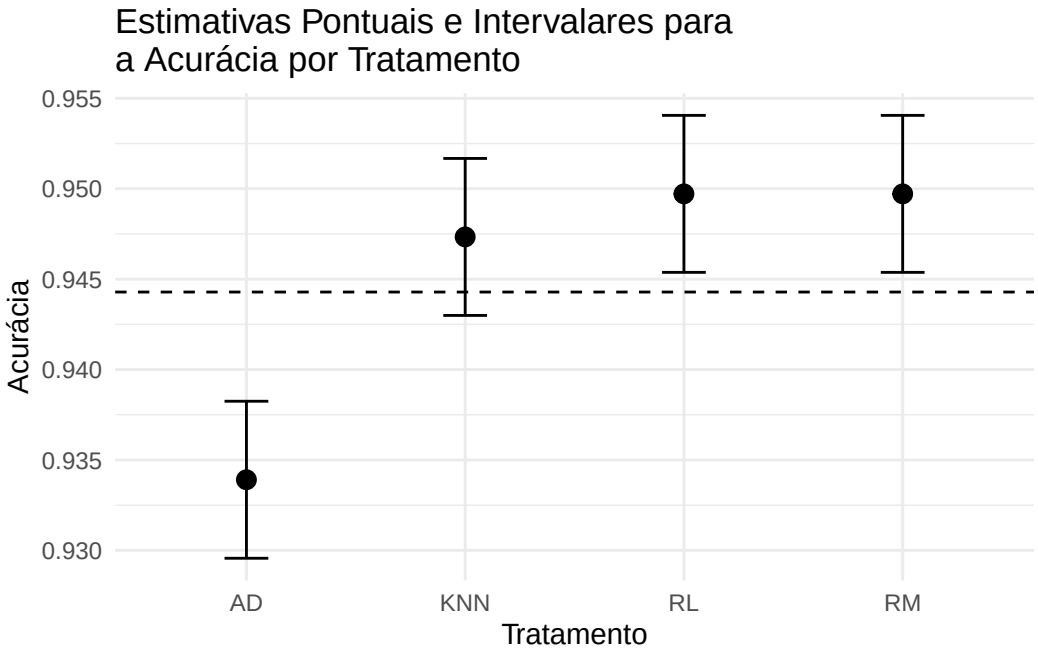

O gráfico acima mostra os intervalos com 95% de confiança para as médias de cada modelo de acordo com a equação:

$$IC[\mu_i, 95\%] = \left[\mu_i - t_{24,\alpha=0.025} \cdot \sqrt{\frac{QMres}{r_i}}, \mu_i + t_{24,\alpha=0.025} \cdot \sqrt{\frac{QMres}{r_i}}\right]$$

. Conforme os valores descritos na tabela para cada tratamento.

```
# A tibble: 4 x 4
  Tratamento `Limite inferior` `Estimativa Pontual` `Limite superior`
  <chr>                  <dbl>                <dbl>             <dbl>
1 AD                     0.930                0.934             0.938
2 KNN                    0.943                0.947             0.952
3 RL                     0.945                0.950             0.954
4 RM                     0.945                0.950             0.954
```

4.2 Teste de Tukey

```
  Tukey multiple comparisons of means
    95% family-wise confidence level

Fit: aov(formula = Acuracia ~ Tratamento, data = DIC)

$Tratamento
                diff          lwr         upr     p adj
KNN-AD  1.342857e-02  0.005222894 0.021634249 0.0007724
RL-AD   1.580952e-02  0.007603846 0.024015201 0.0001044
RM-AD   1.580952e-02  0.007603846 0.024015201 0.0001044
RL-KNN  2.380952e-03 -0.005824725 0.010586630 0.8535179
RM-KNN  2.380952e-03 -0.005824725 0.010586630 0.8535179
RM-RL  -1.110223e-16 -0.008205678 0.008205678 1.0000000


     Acuracia groups
RL  0.9497143      a
RM  0.9497143      a
KNN 0.9473333      a
AD  0.9339048      b
```

O teste de Tukey revelou que os modelos de Regressão Logística, Random Machines e KNN possuem variações semelhantes entre si, e que a variação do modelo de Árvores de Decisão é diferente dos demais modelos, o que está de acordo com o que observamos na análise exploratória inicial.

5 Conclusão

Com todos os testes de adequação de com as suposiçãos do modelo, podemos concluir que o modelo de ANOVA é adequado para a análise dos dados, e que as conclusões tiradas a partir dele são confiáveis.

O teste da ANOVA revela que de fato há evidências de que pelo menos um dos modelos possui variância divergente dos outros modelos.

Como não havia nenhuma suposição prévia sobre os modelos, realizamos em seguida o teste de Tukey que separou os quatro modelos em dois grupos de variações, Grupo A para Regressão Logística, Random Machines e KNN, e grupo B para Árvore de Decisão.

Podemos concluír que para este problema de classificação, onde ambas as duas distribuições de cada classe seguem distribuição normal e são quase linearmente separáveis, o modelo de árvore de decisão irá performar pior que os demais modelos.

6 Recomendações para estudos futuros

Para estudos futuros:

- Mudar o mecanismo gerador dos dados
- Testar outros fatores como tamanho da amostra
- Dados com comportamentos diferentes, como não linear e não simétricos
- Realizar o experimento em dados reais
- Quantidades de covariáveis
- Tipos de covariáveis diferentes, como categóricas e ordinais

7 Referências

Códigos utilizados disponíveis em: https://github.com/Vitor-Pignatari/Projeto-integrador—Planejamento-de-experimentos

RIBEIRO JUNIOR, Paulo Justiniano; MAYER, Fernando Pol. Materiais da disciplina CE312. Curitiba: LEG/DEST/UFPR. Disponível em: http://www.leg.ufpr.br/~paulojus/CE312/materiais.html. Último acesso em: 26 abr. 2026.

Anderson Ara, Mateus Maia, Francisco Louzada, Samuel Macêdo, Random Machines: A Bagged-Weighted Support Vector Model with Free Kernel Choice, J. data sci. 19(2021), no. 3, 409-428, DOI 10.6339/21-JDS1014. Disponível em: https://jds-online.org/journal/JDS/article/899/info

PEREZ, Fernando Lucambio. Notas de aula, 2026. Disponível em: https://estatistica.c3sl.ufpr.br/~lucambio/CE313/20241S/ENP03.pdf . Último acesso em: 26 abr. 2026.

MENDES, Amanda Merian Freitas. Notas de aula, 2026.